

INFORME DE SEGMENTACIÓN ESTRATÉGICA DE CLIENTES MEDIANTE APRENDIZAJE NO SUPERVISADO

Materia: Analítica de Datos y Aprendizaje No Supervisado

Institución: Campus Cámara Comercio Sevilla - Centro FP Superior

1. Tarea 1: Carga y Preprocesamiento de Datos

1.1 Carga e inspección de datos

La integridad de un modelo analítico depende fundamentalmente de la calidad del dato de entrada. En entornos de Retail, es imperativo realizar una auditoría exhaustiva del formateo de archivos CSV. Un error común pero crítico es la presencia de espacios en blanco ocultos o caracteres no imprimibles en las cabeceras de las variables, como ocurre frecuentemente con identificadores del tipo "NumDeals Purchases ". Estos espacios provocan fallos de ejecución en librerías como Pandas al intentar realizar llamadas vectorizadas o selecciones de columnas. Detectar y corregir estos desajustes en la etapa inicial previene errores de "KeyError" y garantiza que los algoritmos de procesamiento posterior operen sobre el esquema de datos correcto.

1.2 Política de imputación de valores faltantes

Para la variable 'Income', la auditoría detectó exactamente 24 registros nulos, determinándose el uso de la mediana como método de imputación para dichos valores. Esta decisión se fundamenta en la naturaleza asimétrica de la distribución de ingresos en poblaciones humanas, la cual suele presentar una "cola larga" a la derecha debido a un grupo reducido de individuos con ingresos desproporcionadamente altos.

A diferencia de la media aritmética, que se ve fuertemente influenciada y desplazada por estos *outliers* o valores atípicos, la mediana es una medida de tendencia central robusta. Utilizar la media en una distribución sesgada introduciría un sesgo artificial, elevando ficticiamente el ingreso promedio del

cliente y distorsionando la realidad socioeconómica del conjunto. La mediana garantiza que el valor imputado sea representativo del "cliente típico".

1.3 Selección de variables y tratamiento de categóricas

En el desarrollo de modelos de *clustering* geométrico, como K-Means, se ha optado por excluir variables demográficas estrictamente categóricas como 'Education' o 'Marital Status'. La justificación técnica radica en que estos algoritmos calculan la similitud basándose en distancias métricas en un espacio n -dimensional.

La aplicación de técnicas como la codificación *One-Hot* transforma estas categorías en variables binarias (0 o 1). Esto introduce una distorsión en la geometría del espacio métrico, ya que el algoritmo interpreta la diferencia entre "Casado" y "Soltero" como una distancia de una unidad, careciendo de un significado escalar real en comparación con variables continuas. En el aprendizaje no supervisado, forzar estas distancias binarias puede segmentar los datos basándose en etiquetas sociales en lugar de comportamientos de consumo reales, diluyendo la eficacia del modelo.

1.4 Justificación del escalado de datos

Es mandatorio aplicar una **Estandarización (StandardScaler)** antes de cualquier algoritmo de agrupación. Los datos del dataset presentan órdenes de magnitud radicalmente distintos: mientras que la variable 'Income' se mide en decenas de miles, 'NumWebVisitsMonth' se expresa en unidades individuales.

Si no se escalan, el cálculo de la distancia Euclidiana otorgará un peso abrumador a la variable con mayor magnitud numérica. El algoritmo consideraría que una diferencia de 1,000 euros en ingresos es mucho más significativa que una diferencia de 5 visitas a la web, cuando para el negocio esta última podría ser un indicador de lealtad mucho más potente. El escalado nivela el terreno de juego, permitiendo que cada variable contribuya equitativamente a la formación de los clústeres.

2. Tarea 2: Clustering con K-Means y Selección de K

2.1 Metodología de selección métrica

Para determinar el número óptimo de clústeres (K), se han evaluado tres criterios técnicos complementarios:

1. **Inercia Cuadrática Interna (Método del Codo - WCSS):** Mide la suma de los cuadrados de las distancias de cada punto a su centroide asignado. Un valor menor indica mayor cohesión interna, buscando el "codo" donde la mejora de la inercia deja de ser drástica.
2. **Coeficiente de Silueta:** Evalúa qué tan similar es un objeto a su propio clúster en comparación con otros clústeres. Valores cercanos a 1 indican una asignación perfecta y grupos bien separados.
3. **Índice de Davies-Bouldin:** Representa el cociente promedio entre las distancias intra-clúster y las distancias inter-clúster. Un valor más bajo indica una mejor partición.

2.2 Justificación de Negocio para el K óptimo

Aunque las métricas matemáticas puras como el Coeficiente de Silueta suelen sugerir soluciones simplistas de $K=2$ o $K=3$, desde una perspectiva de consultoría de negocio en Retail, se ha seleccionado $K=4$. Una segmentación en solo dos grupos resultaría en una abstracción excesiva (ej. "clientes activos" vs "inactivos"), lo cual es insuficiente para el departamento de marketing. $K=4$ proporciona el equilibrio ideal entre granularidad y manejabilidad operativa, permitiendo diseñar tácticas diferenciadas que impacten directamente en el retorno de inversión (ROI) sin dispersar excesivamente los recursos de la empresa.

2.3 Perfiles de Clientes y Estrategias de Marketing

- **Clúster 0: "Clientes Ocasionales de Bajo Valor"**
 - **Perfil:** Ingresos anuales mínimos (35,134.00 €), gasto muy bajo en vinos (39.30 €) y carnes (21.14 €). Registran el mayor volumen de visitas mensuales a la web (6.33 visitas) pero baja conversión final.

- **Estrategia:** Envío masivo de cupones de bienvenida o incentivos agresivos en productos de la canasta básica para aumentar su frecuencia de visita.
- **Clúster 1: "Sibaritas de Alto Valor"**
 - **Perfil:** Ingresos elevados (73,916.04 €), gasto masivo en categorías premium (Vinos: 450.44 €, Carnes: 362.50 €). Alta frecuencia de compra por catálogo (5.60) y en tienda física (8.64).
 - **Estrategia:** Implementación de un programa VIP con acceso a catas exclusivas en tienda física y servicios de *concierge* personal.
- **Clúster 2: "Cazadores de Ofertas Digitales"**
 - **Perfil:** Ingresos medios (53,535.47 €), nivel de gasto en vino aceptable (410.33 €). Destacan de manera sobresaliente por realizar el mayor volumen de compras con descuento (**NumDealsPurchases = 4.47**) y alta interacción web (6.62 visitas).
 - **Estrategia:** Campañas de notificaciones *push* en la aplicación móvil y ofertas relámpago (*flash sales*) semanales enviadas por correo electrónico.
- **Clúster 3: "Compradores Tradicionales de Gasto Moderado"**
 - **Perfil:** Ingresos altos (75,616.25 €), gasto muy alto y diversificado en productos cotidianos (Frutas: 98.07 €, Pescado: 134.11 €, Dulces: 104.22 €). Tienen el menor uso de la web (2.86 visitas) y prefieren comprar presencialmente en la tienda física (8.24 compras).
 - **Estrategia:** Fidelización mediante cupones impresos directamente en el ticket de caja basados en su historial de compras físicas.

3. Tarea 3: Clustering Jerárquico Aglomerativo

3.1 Análisis de Estructura Jerárquica

El Clustering Jerárquico permite entender la relación de "parentesco" entre grupos de datos. Se ha utilizado el **criterio de enlace de Ward**, el cual busca minimizar el incremento de la varianza total dentro de los clústeres en cada paso de fusión. El uso de un dendrograma es vital en esta fase, ya que ofrece una visualización de los niveles macro de fusión natural. A diferencia de K-Means, que fuerza una partición desde el inicio, la jerarquía permite identificar

visualmente en qué punto los clientes se agrupan de forma orgánica antes de imponer un límite rígido de segmentos.

3.2 Comparación de Criterios de Enlace (Linkage)

Al contrastar el método de Ward frente al Enlace Completo (Complete Linkage), se observan diferencias críticas. El Enlace Completo obtuvo un Coeficiente de Silueta de 0.5872, frente al método de Ward con 0.2292. Pese a esta diferencia métrica, Ward es preferido para los objetivos de negocio; la métrica de Complete Linkage se ve distorsionada por la distancia máxima entre *outliers*, mientras que Ward (basado en la minimización de la varianza interna) genera grupos más equilibrados y operacionalmente estables para la interpretación de perfiles de consumo.

4. Tarea 4: Clustering con DBSCAN y Análisis de Ruido

4.1 Fundamento por Densidad

DBSCAN utiliza dos parámetros clave: *eps* y *min_samples*. En este análisis, el algoritmo identificó 4 clústeres y clasificó como ruido a 673 clientes, lo que representa un 30.04% de la base de datos (2,240 registros). Este alto porcentaje de ruido invalida el modelo para estrategias de marketing masivo que requieren la cobertura total de la cartera, ya que el comportamiento humano en Retail forma un espectro continuo donde los clientes transicionan entre perfiles sin interrupciones espaciales claras.

4.2 Significado del Ruido y Ámbitos de Aplicación

Los clientes marcados como ruido representan anomalías extremas: compradores con gastos astronómicos o comportamientos erráticos. Si bien este 30.04% de ruido inutiliza a DBSCAN para campañas de marketing masivo —donde se requiere clasificar a toda la cartera—, lo hace invaluable en otros dominios. Es el algoritmo por excelencia para la detección de fraudes financieros o el análisis de datos geoespaciales para identificar concentraciones anómalas, ya que trata los *outliers* de forma nativa.

5. Tarea 5: Modelo de Mezcla de Gaussianas (GMM)

5.1 Clustering Blando frente a Clustering Duro

A diferencia del "Clustering Duro" de K-Means, donde un cliente pertenece estrictamente a un único grupo, GMM aplica un **"Clustering Blando" (Soft Clustering)**. Matemáticamente, GMM asume que los datos son generados a partir de una mezcla de varias distribuciones gaussianas con parámetros desconocidos. Mediante la función `predict_proba`, el modelo devuelve un vector de probabilidad que indica el grado de pertenencia de un cliente a cada clúster (ej. 80% Clúster A, 20% Clúster B).

5.2 Utilidad de Negocio de las Fronteras Probabilísticas

Esta aproximación es extremadamente valiosa en marketing avanzado. Un ejemplo representativo es el Cliente 5, el cual presenta un vector de probabilidades blandas de [0.0, 0.231, 0.769, 0.0]. Esto indica que su mayor probabilidad (76.9%) corresponde al Clúster 2 ("Cazadores de Ofertas Digitales") y un 23.1% al Clúster 1 ("Sibaritas de Alto Valor"). En lugar de tratarlo simplemente como un buscador de descuentos, el equipo de marketing puede desplegar estrategias mixtas, ofreciéndole productos premium solo cuando estos se encuentren en promoción, capturando así un valor que se perdería con un particionamiento rígido.

6. Tarea 6: Tabla Comparativa y Recomendación Estratégica Final

6.1 Matriz Comparativa de Algoritmos

Algoritmo	Coficiente de Silueta Global	Índice Davies-Bouldin	Número de Clústeres	Porcentaje de Ruido	Ventaja Principal Observada	Limitación Observada
K-Means	0.2598	1.34	4	0%	Alta interpretabilidad, rapidez	Sensible a outliers; asume formas

Algoritmo	Coeficiente de Silueta Global	Índice Davies-Bouldin	Número de Clústeres	Porcentaje de Ruido	Ventaja Principal Observada	Limitación Observada
					computacional y estabilidad temporal.	esféricas rígidas.
Jerárquico (Ward)	0.2292	1.42	4	0%	El dendrograma permite entender las jerarquías de agrupación.	Elevado coste computacional si aumenta el volumen de datos.
DBSCAN	0.1967	1.68	4	30.04%	Capacidad nativa para aislar y etiquetar valores atípicos (outliers).	Ineficaz ante densidades continuas comerciales; genera excesivo ruido.
GMM	0.0942	3.12	4	0%	Proporciona una asignación probabilística flexible y blanda.	Mayor complejidad matemática para trasladar las reglas al negocio.

6.2 Defensa de la Solución en Producción

Se selecciona **K-Means** como el modelo definitivo para su implementación en producción por las siguientes razones:

1. **Interpretabilidad e Implementación Directa:** Los centroides de K-Means representan el promedio de las características de cada grupo, lo que permite traducir los resultados en reglas de negocio lógicas y comprensibles para los gerentes de marca sin necesidad de formación técnica avanzada.
2. **Estabilidad Temporal:** Al utilizar una semilla aleatoria fija (*seed*), el modelo garantiza la reproducibilidad de los resultados. Esto es crítico para monitorizar la migración de clientes entre segmentos mes a mes, evaluando si las campañas de marketing están logrando "ascender" a los clientes a categorías de mayor valor.

3. **Escalabilidad Computacional:** K-Means posee una complejidad algorítmica lineal respecto al número de registros. A medida que la base de datos del supermercado crezca de miles a millones de transacciones, K-Means seguirá siendo ejecutable en tiempos breves, a diferencia de los métodos jerárquicos.